

工学逆問題における不確実性定量化のための

潜在空間ベイズ推論フレームワーク構築

A Latent-Space Bayesian Inference Framework for
Uncertainty Quantification in Engineering Inverse Problems

指導教員 村上健太 准教授

03-250919 笠井優作

1. 研究の背景 — 工学逆問題と不確実性定量化

工学では「観測データからモデルパラメータを推定」する逆問題が遍在

- 構造物の剛性・減衰の同定、材料定数・損傷度の推定、流体・熱輸送パラメータの推定
- 診断・リスク評価・意思決定には、推定の **不確実性定量化** が不可欠

点推定では不十分な理由:

- **観測情報の制約**による **等価性（識別不能性）** — 異なるパラメータ配分が同じ応答を出すケースがあり、点推定は **複数の解候補を見落とす**
- 信頼区間・分散など **「どの程度信頼できるか」** が出ない

ベイズ推論 は事後分布として不確実性を直接与える:

$$p(\theta \mid x_{\text{obs}}) \propto \underbrace{L(\theta; x_{\text{obs}})}_{\text{尤度}} \cdot \underbrace{p(\theta)}_{\text{事前}}$$

2. 本研究の目的 — フレームワーク構築

ベイズ推論の実用上の壁: 高コストなシミュレータ呼び出し

→ これを回避できる **潜在空間ベイズ推論 (LSBI)** が近年提案されている (Yaoyama 2026 ほか)

しかし: 既存実装は特定の手法構成 (MVAE + SMC など) に **固定** されており、他手法との比較や差し替えが難しい

本研究の目的:

LSBI を起点に、**各構成要素を後から差し替え可能** とした推論フレームワークを構築する

- 尤度モデル・サンプラー・MCMC カーネルなどを **共通インターフェース** で抽象化
- 「**どの手法がどの問題に最適か**」を共通ベンチマーク上で **横断比較** できる土台を作る

3. 潜在空間ベイズ推論 — 定式化


ベイズの定理より:

$$p(\theta \mid x_{\text{obs}}) \propto L(\theta; x_{\text{obs}}) p(\theta) \quad (1)$$


低次元潜在変数 z を介して尤度を近似する。観測側エンコーダ $q_{\phi_x}(z \mid x_{\text{obs}})$ 、パラメータ側エンコーダ $q_{\phi_\theta}(z \mid \theta)$ 、潜在事前 $p(z) = \mathcal{N}(0, I)$ を **全てガウス** として構成すれば、

$$\hat{L}(\theta; x_{\text{obs}}) = \int \frac{q_{\phi_x}(z \mid x_{\text{obs}}) q_{\phi_\theta}(z \mid \theta)}{p(z)} dz \quad (2)$$

は **閉形式で評価可能** となる。




4. 全体像 — オフライン/オンラインの 2 段構成



- **オフライン**: 事前から (θ, x) サンプル $\rightarrow$ MVAE 学習 $\rightarrow$ 近似尤度 $\hat{L}$ 構築
- **オンライン**: SMC が $\hat{L}$ のみと呼び事後分布から粒子をサンプリング $\rightarrow$ 推論ループで **シミュレータを**

5. Multimodal Variational Autoencoder (MVAE) の学習



- **MVAE = 2 エンコーダ + 1 デコーダ** で、観測 x (FRF) とパラメータ θ を **共有潜在空間** に写す
- **学習:** 双方向 KL + 再構成損失 $\rightarrow$ 2 エンコーダ出力が同じ潜在空間で **重なる** よう整列
- **学習後の使い道:** 学習済みエンコーダ $q_{\phi_x}, q_{\phi_\theta}$ が、そのまま **式 (2) の被積分関数として近似尤度 $\hat{L}$ の計算に投入される**

6. フレームワーク実装① — 概念的役割への分離

文献 1) で採用されている具体手法を、**共通の概念的役割** に分離して整理:

概念的役割	現実装	差し替え候補
尤度モデル	MVAE 潜在尤度	Normalizing Flow / 拡散モデル / 直接尤度
サンプラー	焼きなまし型 SMC	HMC / NUTS / Nested Sampling
MCMC カーネル	RW-Metropolis	MALA / HMC ステップ
提案分布	Ching & Chen (2007)	適応 MH / 学習済み提案
事前分布	HierarchicalPrior (DAG)	任意の確率変数 DAG

ねらい: 「どの手法を採用するか」と「上位ロジック」を分離し、後から **差し替え** できる構造にする

7. フレームワーク実装② — Protocol によるインターフェース

各概念的役割を Python の `Protocol` で **インターフェースのみ宣言**:

```
class LikelihoodProtocol(Protocol):
    def __call__(self, theta: Theta) -> LP: ...

class KernelProtocol(Protocol):
    def __call__(
        self, particles: Particles, q: float,
        prior: PriorProtocol, likelihood: LikelihoodProtocol,
    ) -> tuple[Pop, LP, Mask]: ...
```

図 1 代表的な Protocol 定義（抜粋）

- 具体実装は Protocol にのみ依存し、上位ロジックは具体クラスを知らない
- 新しい尤度モデル・サンプラーを **継承なし** に 持ち込める（構造的部分型）

→ 設計思想: 「**どの手法がどの問題に最適か**」を共通ベンチマーク上で **横断比較** できる構成

8. 検証 — 4自由度せん断建物

ベンチマーク (Yaoyama 2026 と同じ):

- 4 自由度せん断建物の 層剛性同定問題
- 観測は 屋上 FRF (1024 点) のみ
- $\theta_i \in [0.33, 3.00]$ 、真値 $\theta = (1, 1, 1, 1)$
- 観測の制約から 真値以外に 3 つの等価解 が存在することが既知

学習設定:

- 訓練データ: 事前分布から生成した 10^5 サンプル
- MVAE: 潜在次元 8、早期終了付き

→ 多峰性が現れる古典的ベンチマークでフレームワークの動作確認

9. 検証 — 結果


SMC: 粒子数 2000、GPU 上で実行

事後分布散布図（右図）：

- **真値** (1, 1, 1, 1) に対応する集中モード
- **既知の等価解 3 点** にも別モードが立つ

→ 観測の制約に由来する **多峰性**を本フレームワークが正しく追跡 できることを確認

→ Slide 1 で挙げた **等価性** を「単一解に押し込めず、事後分布で正直に表現」できている



10. 課題と今後

現状の限界:

- 検証は 4DOF せん断建物のみ
- 他の尤度モデル・サンプラーは未実装、横断比較はこれから

今後:

🎯 尤度モデル拡張を最優先課題 とする

- **Normalizing Flow / 拡散モデル** 等を実装
- 同一ベンチマーク上で **横断比較**

→ 複雑系へ適用を広げ、**汎用ライブラリへ発展** させる

ご清聴ありがとうございました