

工学逆問題における不確実性定量化のための

潜在空間ベイズ推論フレームワーク構築

A Latent-Space Bayesian Inference Framework for
Uncertainty Quantification in Engineering Inverse Problems

指導教員 村上健太 准教授

03-250919 笠井優作

1. 研究の背景 — 工学逆問題と不確実性定量化

工学では「観測データからモデルパラメータを推定」する逆問題が遍在

- 構造物の剛性・減衰の同定、材料定数・損傷度の推定、流体・熱輸送パラメータの推定
- 診断・リスク評価・意思決定には、推定の **不確実性定量化** が不可欠

点推定では不十分な理由:

- **観測情報の制約**による **解の非一意性** — 異なるパラメータ配分が同じ応答を出すケースがあり、点推定は **複数の解候補を見落とす**
- **精度・不確実性** がわからない

ベイズ推論 は事後分布として不確実性を直接与える:

$$p(\theta \mid x_{\text{obs}}) \propto \underbrace{L(\theta; x_{\text{obs}})}_{\text{尤度}} \cdot \underbrace{p(\theta)}_{\text{事前}}$$

2. 本研究の目的 — フレームワーク構築

ベイズ推論の実用上の壁: 高コストなシミュレータ呼び出し

→ これを回避できる **潜在空間ベイズ推論 (LSBI)** が近年提案されている (Yaoyama et al., 2026)

しかし: 既存実装は特定の手法構成 (MVAE + SMC など) に **固定** されており、他手法との比較や差し替えが難しい

本研究の目的:

LSBI を起点に、**各構成要素を後から差し替え可能** とした推論フレームワークを構築する

- 尤度モデル・サンプラー・MCMC カーネルなどを **共通インターフェース** で抽象化
- 「**どの手法がどの問題に最適か**」を共通ベンチマーク上で **横断比較** できる土台を作る

3. 潜在空間ベイズ推論 — 定式化


ベイズの定理より:

$$p(\theta \mid x_{\text{obs}}) \propto L(\theta; x_{\text{obs}}) p(\theta) \quad (1)$$


低次元潜在変数 z を介して尤度を近似する。観測側エンコーダ $q_{\phi_x}(z \mid x_{\text{obs}})$ 、パラメータ側エンコーダ $q_{\phi_\theta}(z \mid \theta)$ 、潜在事前 $p(z) = \mathcal{N}(0, I)$ を **全てガウス** として構成すれば、

$$\hat{L}(\theta; x_{\text{obs}}) = \int \frac{q_{\phi_x}(z \mid x_{\text{obs}}) q_{\phi_\theta}(z \mid \theta)}{p(z)} dz \quad (2)$$

は **閉形式で評価可能** となる。




4. 全体像 — オフライン/オンラインの 2 段構成



- **オフライン**: 事前から (θ, x) サンプル → MVAE 学習 → 近似尤度 $\hat{L}$ 構築
- **オンライン**: SMC が $\hat{L}$ のみと呼び事後分布から粒子をサンプリング → 推論ループで **シミュレータを**

5. Multimodal Variational Autoencoder (MVAE) の学習



- **MVAE: 2encoder + 1decoder**、観測 x （周波数応答関数）とパラメータ θ が **共有潜在空間** z を經由して対応
 - **学習**: 双方向 KL + 再構成損失 $\rightarrow$ 2 エンコーダ出力が同じ潜在空間で **重なる** よう整列
 - **学習後の使い道**: 学習済みエンコーダ $q_{\phi_x}, q_{\phi_\theta}$ が、そのまま **式 (2) の被積分関数として近似尤度 $\hat{L}$ の計算に投入される**
- 工学逆問題における不確実性定量化のための潜在空間ベイズ推論フレームワーク構築

6. フレームワーク実装① — 概念的役割への分離

(yaoyama et al., 2026) で採用されている具体手法を、**共通の概念的役割** に分離して再定義:

概念的役割	現実装	差し替え候補
尤度モデル	MVAE 潜在尤度	Normalizing Flow / 拡散モデル / 直接尤度
サンプラー	焼きなまし型 SMC	HMC / NUTS / Nested Sampling
MCMC カーネル	RW-Metropolis	MALA / HMC ステップ
提案分布	Ching & Chen (2007)	適応 MH / 学習済み提案
事前分布	HierarchicalPrior (DAG)	任意の確率変数 DAG

ねらい: 「どの手法を採用するか」と「上位ロジック」を分離し、後から **差し替え** できる構造にする

7. フレームワーク実装② — Protocol によるインターフェース

各概念的役割を Python の `Protocol` で **インターフェースのみ宣言**:

```
class LikelihoodProtocol(Protocol):
    def __call__(self, theta: Theta) -> LP: ...

class KernelProtocol(Protocol):
    def __call__(
        self, particles: Particles, q: float,
        prior: PriorProtocol, likelihood: LikelihoodProtocol,
    ) -> tuple[Pop, LP, Mask]: ...
```

図 1 代表的な Protocol 定義（抜粋）

- 具体実装は Protocol にのみ依存し、上位ロジックは具体クラスを知らない
- 新しい尤度モデル・サンプラーを **継承なし** に 持ち込める（構造的部分型）

→ 設計思想: 「**どの手法がどの問題に最適か**」を共通ベンチマーク上で **横断比較** できる構成

8. 検証 — 4自由度せん断建物

ベンチマーク (Yaoyama et al., 2026 と同じ題材):

- 4 自由度せん断建物の **層剛性同定問題**
- 観測は **屋上の1観測点の周波数応答関数** (1024 次元) のみ
- $\theta_i \in [0.33, 3.00]$ 、真値 $\theta = (1, 1, 1, 1)$
- 観測の制約から **真値以外に 3 つの等価解** が存在することが既知

学習設定:

- 訓練データ: 事前分布から生成した 10^5 サンプル
- MVAE: 潜在次元 8、早期終了付き

→ 多峰性が現れる古典的ベンチマークでフレームワークの動作確認

9. 検証 — 結果


SMC: 粒子数 2000、GPU 上で実行

事後分布散布図（右図）：

- **真値** (1, 1, 1, 1) に対応する集中モード
- **既知の等価解 3 点** にも別モードが立つ

→ 観測の制約に由来する **多峰性を本フレームワークが正しく追跡** できることを確認

→ **同一応答を与える別パラメータ解** を「単一解に押し込めず、事後分布で正直に表現」できている



10. 課題と今後

現状の限界:

- 検証は 4DOF せん断建物のみ
- 他の尤度モデル・サンプラーは未実装、横断比較はこれから

今後:

🎯 尤度モデル拡張を最優先課題 とする

- **Normalizing Flow / 拡散モデル** 等を実装
- 同一ベンチマーク上で **横断比較**

→ 複雑系へ適用を広げ、**汎用ライブラリへ発展** させる

ご清聴ありがとうございました